




OCR-Qualität ohne Ground Truth bemessen

Von globaler Korpusdiagnose zu lokaler Evidenz

ZB Sommerschule 2026: Longue Durée digital

Dr. Simon Clematide



Einziges manuell erstellte Slide in dieser Präsentation

Dankeschön

- impresso Team an EPFL, C2DH, UNIL und UZH
- Glebs Vinarski für die Implementation der OCRQA-Pipeline
- ChatGPT 5.5 für das Lesen der bereitgestellten Unterlagen, Diskussionsbereitschaft, Vortragsentwicklung, textueller Beschreibung der Slides
- Gemini für das Erstellen der Slides aus den ChatGPT Texten

Quelle: [Vollständiger ChatGPT Chat](#)

Google Slides
(kommentierbar für alle)



1. Warum OCRQA?

OCR-Qualität als Voraussetzung für Suche, Statistik und Interpretation.

Warum OCR-Qualität zählt

OCR-Qualität ist kein technisches Randproblem. Sie beeinflusst alle späteren Analyseschritte.



OCRQA = OCR Quality Assessment

Heuristische Einschätzung der OCR-Qualität ohne Ground Truth.

Ziel: problematische Texte, Zeitungen oder Jahre sichtbar machen, bevor wir sie analysieren.

Das Grundproblem

Mit Ground Truth

- CER / WER berechenbar
- präzise Evaluation
- teuer und selten repräsentativ

Ohne Ground Truth

- indirekte Signale
- skalierbar
- heuristisch

CER kurz erklärt

CER = Character Error Rate

Anteil der Zeichenfehler im Vergleich zu einer korrekten Transkription.

OCR: Regierung

GT: Regierung

→ 1 Zeichenfehler

WER = Word Error Rate: analog auf Wortebene.

In grossen historischen Korpora gibt es selten Ground Truth für jede Zeitung, jedes Jahr, jede Sprache und jedes Layout.

Was kann ohne Ground Truth als Evidenz dienen?

Ohne Ground Truth arbeiten wir mit indirekten Signalen. Jedes Signal ist nützlich, aber begrenzt.

1. Bild / Faksimile

- Scanqualität
- Blur, Flecken, Verzerrung
- Schrift und Layout

2. OCR-System

- Konfidenzwerte
- Bounding Boxes
- Segmentierung

3. Textoberfläche

- Bekannte / unbekannte Wörter
- Zeichen-n-Gramme
- Garbage Tokens

4. Sprachmodell

- Plausibilität
- Perplexität
- Pseudo-Perplexität

**Ground-truth-freie OCRQA ist
kein Ersatz für Ground Truth,
sondern ein skalierbares Warnsystem.**

Die einfache Idee von OCRQA

Ein Text wirkt zuverlässiger, wenn viele seiner unterschiedlichen Wortformen in einer passenden Referenzliste vorkommen.

OCRQA = bekannte Wortformen / (bekannte Wortformen + unbekannte Wortformen)

Wortformen = Types, nicht Token-Vorkommen

Bekannte Wortformen

Zeitung, Regierung, heute

Unbekannte Wortformen

Regierunq, hente, Vegehr


Hinweis: Unbekannt bedeutet nicht automatisch OCR-Fehler. Es kann auch ein Name, eine historische Schreibung, ein Fremdwort oder eine Lücke im Lexikon sein.

2. Wie funktioniert OCRQA?

Von Wortformen zu Scores — und von Scores zu Diagnose.

OCRQA Schritt 1: Text normalisieren

Bevor OCRQA zählen kann, wird der OCR-Text vereinfacht und in vergleichbare Wortformen zerlegt.



- Gross-/Kleinschreibung vereinheitlichen
- Satzzeichen und nicht-alphabetische Zeichen behandeln
- Ziffern normalisieren: 1858 → 0000
- unterschiedliche Tokens (Types) statt alle Tokens zählen

Warum Types?

Häufige Funktionswörter würden Token-Zählungen dominieren.
Types geben seltenen Inhaltswörtern mehr Gewicht.

Beispiel:

Original: “Kinjd”, “nacb”, “Vegehr”

Tokenliste: *kinjd, nacb, vegehr*

⚠ Achtung:

Falsche Sprachwahl oder kurze OCR-Artefakte können den Score verzerren.

OCRQA Schritt 2: Wörter nachschlagen

Jede eindeutige Wortform wird gegen eine grosse sprachspezifische Referenzliste geprüft.

Bekannt

- in Referenzliste vorhanden
- plausibles Wort
- zählt positiv

glück

mann

dämon

Unbekannt

- nicht in Referenzliste vorhanden
- möglicher OCR-Fehler
- zählt als Warnsignal

kinjd

nacb

vegehr

Hinweis:

Unbekannte Tokens sind Kandidaten für Inspektion, keine automatischen Fehlerurteile.

OCRQA Schritt 3: Score berechnen

Der Score ist der Anteil bekannter Wortformen an allen geprüften Wortformen.

$$\text{Score} = \frac{\text{BEKANNT } 42}{\text{BEKANNT } 42 + \text{UNBEKANNT } 8} = \text{SCORE } 0.84$$

Interpretation

nahe 1.0 = viele plausible Wortformen

niedrig = viele Warnsignale

Wichtiger Hinweis: Der Score misst lexikalische Plausibilität, nicht direkt CER oder WER.

OCRQA für einen einzelnen Text

<https://cutt.ly/ocrqa-demo>

Der Score ist nützlich, aber die Liste der unbekannten Tokens ist oft noch wichtiger.

 Spaces |  impresso-project / ocrqa-demo  like 3  Running  

Optical Character Recognition (OCR) Quality Assessment Demo

This demo evaluates OCR quality by comparing the unique words in a text against large reference vocabularies.

It reports:

- potential OCR errors (unrecognized unique tokens) and known tokens
- an overall **quality score** between 0.0 (poor) and 1.0 (perfect), defined as $\text{score} = \text{known} / (\text{known} + \text{unrecognized})$

Try the German example below or paste your own OCR text.

OCR input text

Bereits vor 5 Jahren arbeitete der Große Rat des Kt. Wallis ein neues Armengesetz aus. In der Volksabstimmung vom 4. Dezember 1921 wurde der Entwurf aber verworfen. Heute liegt nun ein neuer Gesetzesentwurf vor. Die Hauptfächlichsten Bestimmungen dieses Gesetzes lauteu:

Language of the input text

de

OCR Quality Assessment

 Language: de

 Quality Score: 0.95 (35/37)

 Known unique tokens (35):
. 0 0000 : aber arbeitete armengesetz aus bereits bestimmungen der des dezember die dieses ein entwurf gesetzes gesetzesentwurf große heute in jahren kt liegt neuer neues nun rat verworfen volksabstimmung vom vor wallis wurde

 Unrecognized unique tokens (2):
hauptfächlichsten lauteu

 Model: ocrqa-wp_v2.0.0-de

 Assess OCR Text Quality

Aufgabe:

- 1. Text aus impresso kopieren
- 2. Sprache wählen
- 3. OCRQA berechnen
- 4. unbekannte Tokens prüfen
- 5. entscheiden: Fehler oder gültiges Wort?

**Nicht nur auf den Score schauen —
die Diagnose erklärt den Score.**

Was zeigt der schlechteste Score?

Low OCRQA is an invitation to **inspect**.

1. Material

- z.B. Handschrift statt Druck
- ungewöhnliche Quelle im Zeitungskorpus

2. Verarbeitung

- OCR-Modell passt nicht zum Material
- Segmentierung kann scheitern

3. Interpretation

- nicht blind ausschliessen
- als Sonderfall dokumentieren
- ggf. separat behandeln

Aggregierte OCRQA-Werte können stark streuen

Ein Durchschnittswert pro Zeitung und Jahr verdeckt lokale Unterschiede. Einzelne Seiten, Regionen oder Artikel können deutlich schlechter sein.



1. Aggregation

- Zeitung-Jahr als Durchschnitt
- Ausreisser werden geglättet
- Varianz bleibt wichtig

2. Lokale Ursachen

- Scanfehler
- Schatten / Finger
- kleine Schrift
- Anzeigen und Tabellen
- Segmentierungsfehler

3. Interpretation

- Durchschnitt nicht blind vertrauen
- auffällige Jahre inspizieren
- Beispiele im Faksimile prüfen

OCRQA ist ein Einstieg in Quellenkritik, nicht deren Ersatz.

3. Was steckt im Messinstrument?

Lexika, Normalisierung, Bloomfilter und Kuratierung.

Lexika als Messinstrumente

OCRQA hängt davon ab, welche Wortformen als „bekannt“ gelten. Die Wortliste ist Teil der Messung.




- gute Lexika reduzieren falsche Warnungen
- schlechte Lexika erzeugen Scheingenauigkeit
- unkritische Ergänzungen können echte OCR-Fehler verdecken

Lexikonpflege ist methodische Arbeit.

Technischer Einschub: Warum Bloomfilter?

Ein Bloomfilter speichert sehr grosse Wortlisten kompakt und erlaubt extrem schnelle „Ist dieses Wort bekannt?“-Abfragen.



Trade-off

- Vorteile: Sehr kompakt, extrem schnell
- Ideal für riesige Lexika
- Grenze: False positives möglich (aber einstellbares Risiko)


Lexikonaufbau: grosse Referenzlisten

OCRQA nutzt grosse, kuratierte Wortlisten. Wikipedia und Wortschatz Leipzig liefern moderne Wörter und Eigennamen; historische Zeitungstexte erfordern zusätzliche Filterung und Kuratierung.

1. Warum Wikipedia + Wortschatz Leipzig?

- grosse mehrsprachige Korpora
- viele moderne Wörter
- Personen, Orte, Organisationen
- gute Startabdeckung

2. Adaptive Frequenzschwelle für Deutsch v2



Konfiguration (Deutsch v2):

- 1 Zeichen → 2500
- 2 Zeichen → 625
- 3 Zeichen → 278
- 4 Zeichen → 157
- 5 Zeichen → 100
- 10 Zeichen → 25
- 35+ Zeichen → 2

Deutsch v2 nutzt eine deutlich strengere, längenadaptive Schwelle.

3. Systematische Erweiterung

- unbekannte Tokens auf grossem Korpus berechnen
- nach Häufigkeit sortieren
- von häufig zu seltener manuell triagieren
- Real Words ergänzen
- Non-Words / OCR-Artefakte ausschliessen

Nicht exhaustive: historische Schreibungen, Luxemburgisch und Eigennamen bleiben schwierig.

Aufgabe: Lexikon kuratieren

Unbekannte Tokens sind nicht nur Fehler. Sie zeigen auch, wo Sprachressourcen fehlen.

Aufgabe:

Übertragen Sie ausgewählte unbekannte Tokens aus dem OCRQA-Demo in das Google Sheet.

Entscheidungskategorien:

- gültiges modernes Wort
- historische Schreibung
- Eigenname
- Fremdwort / Sprachmischung
- OCR-Fehler / Non-Word
- unsicher


<https://cutt.ly/ocrqa-lex>

A	B
Simple lexicon curation workbook	
For each language, enter the candidate token as text and make two simple decisions.	
Use https://huggingface.co/spaces/impresso-project/ocrqa-demo and impresso texts.	
Column	Use
Candidate word/token	Text field for the observed word or OCR token being reviewed.
Decision	Choose Real Word or Non-Word.
Spelling type	Choose Modern or Historical.
Notes / comments	Optional reasoning, evidence, uncertainty, or merge hints.

Instruktion: Ziel ist nicht ein perfekter Score um jeden Preis, sondern die Unterscheidung zwischen Lexikonlücke und echtem OCR-Fehler.

Vom Einzeltext zur Korpusdiagnose


Wenn derselbe OCRQA-Score systematisch berechnet wird, können wir Qualität über Zeitungen, Jahre und Anbieter vergleichen.



Demo: OCRQA über Zeitungen und Jahre

<https://cutt.ly/ocrqa-exploration>

OCR-Qualität ist im Korpus ungleich verteilt. Sie hängt von Zeitung, Jahr, Anbieter, Layout, Schrift und Materialtyp ab.



- jede Zeitung hat ein eigenes Qualitätsprofil
- Jahresverläufe zeigen Brüche und Ausreisser
- Anbieter und OCR-Pipelines hinterlassen Spuren
- niedrige Scores führen zur Quelleninspektion

Gruppenaufgabe: Vom Score zurück zur Quelle


<https://cutt.ly/ocrqa-exploration>

Ein niedriger oder auffälliger OCRQA-Verlauf ist kein Endergebnis. Er ist ein Hinweis für Quelleninspektion.

Trend / Bruch → Zeitung anschauen → Quellenintuition

Aufgabe: Zu zweit oder zu dritt

- Öffnen Sie den aggregierten OCRQA-Space.
- Wählen Sie Deutsch oder Französisch.
- Suchen Sie auffällige Trends, Brüche oder Ausreisser.
- Notieren Sie Zeitung, Jahr und Anbieter.
- Öffnen Sie passende Beispiele in der impresso-Webapp.
- Schauen Sie das Material exemplarisch an: passt Ihre Intuition zum OCRQA-Verlauf?



Diskussionsfragen:

- Gibt es sichtbare Brüche über die Zeit?
- Was könnte die Veränderung erklären?
- Was ist am Material besonders: Layout, Schrift, Sprache, Handschrift, Anzeigen, Tabellen?

4. Was tun bei schlechter OCR?

Inspizieren, kuratieren, neu erkennen oder nachkorrigieren.

OCRQA in der Forschungspraxis

OCRQA sollte nicht nur beschrieben werden. Sie sollte Entscheidungen im **Forschungsdesign** beeinflussen.

Vor diesen Methoden fragen:

Frequenzen

Keyness

Kollokationen

Embeddings

Klassifikation



Welche Zeitungen und Jahre sind schwach?



Ist niedrige Qualität systematisch verteilt?



Ändern sich Ergebnisse ohne schwache Teilkorpora?



Müssen problematische Quellen separat berichtet werden?



Ist ReOCR, Post-Correction oder manuelle Kontrolle sinnvoll?

ReOCR: gezielt neu erkennen

Aggregierte OCRQA-Werte helfen, Kandidaten zu finden. Lokale Evidenz zeigt, ob eine neue OCR tatsächlich nützt.

ReOCR = erneute OCR ausgewählter Zeitungen mit besseren oder passenderen Modellen.



REOCR: Zeilenvergleich mit Konfidenz

REOCR kann historische Zeitungstexte deutlich lesbarer machen. Die Konfidenzwerte liefern zusätzlich lokale Evidenz.


90

Original OCR:

In Ocstcirsch hcirjcht einc gienzeniofe Vecwii-

REOCR:

In Oesterreich herrscht eine grenzenlofe Verwir

A snippet of a historical manuscript in Fraktur script, showing the text 'In Oesterreich herrscht eine grenzenlofe Verwir'.


84

Original OCR:

geoidnclc » auf dcn Lanotage » z » überzeugen , dc . ß

REOCR:

geordneten auf den Landtagen zu überzeugen, daß

A snippet of a historical manuscript in Fraktur script, showing the text 'geordneten auf den Landtagen zu überzeugen, daß'.


91

Original OCR:

wurzelt) durch die Ungar « , Czechc » und Po \! -. » , daS

REOCR:

wurzelt) durch die Ungarn, Czechen und Polen, das

A snippet of a historical manuscript in Fraktur script, showing the text 'wurzelt) durch die Ungarn, Czechen und Polen, das'.


92

Original OCR:

ist die Hoffn-i » g gcsticge » , indem von dcr Negierang

REOCR:

ist die Hoffnung gestiegen, indem von der Regierung

A snippet of a historical manuscript in Fraktur script, showing the text 'ist die Hoffnung gestiegen, indem von der Regierung'.

Was bedeuten Konfidenzwerte konkret?

Konfidenzwerte sind lokale Warnsignale: tiefe Werte markieren Zeilen, die besonders prüfbedürftig sind.

21

CONF

"ulnd Pießfeeihett find gewbahrteiftter. Guütertonfisra"

sehr verdächtig

42

CONF

"vhnd daß desball das dand meßr abtrfat als frber"

teilweise lesbar

62

CONF

"Statt allen Anpreisungen diene dem E Publikum"

brauchbar

92

CONF


"Es ift noch in frifchem Andenken, wie"

sehr plausibel

Schwellen sind modellabhängig. Beim hier verwendeten Tesseract-Fraktur-Modell sind Werte unter ca. 30 meist sehr problematisch.

Alternative zu ReOCR: OCR Post-Correction

Wenn das Bild nicht neu verarbeitet wird, kann man den vorhandenen OCR-Text nachträglich korrigieren — heute oft mit LLM-Unterstützung.



Post-Correction ist nicht risikofrei: Systeme können verbessern, aber auch verschlechtern oder historisch relevante Formen modernisieren.

Drei Takeaways

OCRQA macht Textqualität nicht perfekt messbar, aber sichtbar und diskutierbar.

01

Heuristik vs. Messung

Ohne Ground Truth bleiben
Qualitätswerte heuristisch.

02

Methodischer Nutzen

OCRQA hilft bei Exploration, Triage
und Quellenkritik.

03

Ebenen der Analyse

Scores brauchen Interpretation:
global, lokal und philologisch.

Nicht der Score entscheidet — die Kombination aus Messung, Inspektion und Kontext.

Literatur und Ressourcen

Ground-truth-free OCR/HTR evaluation

Ströbel et al. 2022
Evaluation of HTR Models...
arxiv.org/abs/2201.06170

Schneider & Maurer 2022
Rerunning OCR: Quality...
arxiv.org/abs/2110.01661

Springmann et al. 2016
Automatic quality evaluation...
arxiv.org/abs/1606.05157

Image- and engine-based estimation

Blando et al. 1995
Prediction of OCR Accuracy Using Simple
Image Features

Gupta et al. 2015
Automatic Assessment of OCR Quality...
doi.org/10.1609/aaai.v29i1.9487

Demos und Materialien

OCRQA text demo
huggingface.co/spaces/.../ocrqa-demo

OCRQA exploration
huggingface.co/spaces/.../ocrqa-exploration

Bloomfilter cookbook
github.com/impresso/ocrqa-bloomfilter...

impresso Webapp
impresso-project.ch/app

Post-Correction

HIPE-OCRepair 2026
LLM-Assisted OCR Post-Correction for
Historical Documents
hipe-eval.github.io/HIPE-OCRepair-2026/

Deutsch-Lexikon: von v1 zu v2

Die neuere OCRQA-Version ist strenger und OCR-sensitiver: Sie behandelt Artefakte expliziter und filtert kurze Wortformen aggressiver.

v1.0.6: Legacy

- Normalisierung v1
- Satzzeichen → Leerzeichen
- keine OCR-Artefakt-Isolation
- Frequenzmodus: **legacy**
- min_frequency = 2
- single_char_min_frequency = 500
- false positive probability = 0.00001

Beispiel:

`"hello~world" → hello, world`

v2.0.0: OCR-sensitiver

- Normalisierung v2
- OCR-Artefakte als eigene Tokens
- Frequenzmodus: **adaptive**
- base_frequency = 2500.0
- exponent = 2.0
- min_frequency = 2
- false positive probability = 0.00005

Beispiel:

`"hello~world" → hello, ~, world`

v1 maximiert einfache Abdeckung; v2 reduziert OCR-Rauschen und macht Artefakte sichtbarer.