

```
bins = list(range(start, stop, n_years))
labels = [f"{y}-{y + n_years - 1}" for y in bins[:-1]]


# Assign each document to a year bucket
# With n_years = 25:
# 1833 -> 1825 -> "1825-1849"
# 1900 -> 1900 -> "1900-1924"
# 1898 -> 1875 -> "1875-1899"
self.df["year_interval"] = pd.cut(self.df["year"], bins=bins, labels=labels, right=False)

# Calculate counts for each interval
interval_counters = {}
for interval in tqdm(labels, desc="Iterating intervals"):
    group_df = self.df[self.df["year_interval"] == interval]
```

Summer School: Longue Durée digital – Kulturelle Phänomene und Ungleichheiten mit Machine Learning erforschen, Zürich 17.-18.6.2026

Korpora explorieren: Frequenzen, Kollokationen und Word Embeddings


Xenia Bojarski, UZH (xenia.bojarski@uzh.ch)



Daten
statistisch
auswerten

Daten
aggregieren /
vektorisieren

Iterativ arbeiten



Daten statistisch auswerten: Frequenzen

Was zählen wir überhaupt? | Token und Lemma

Token:

Haus

Häuser

Hauses

= 3 verschiedene Token

→ $\text{count}(\text{Haus}) = 1$

Lemma:

Haus

Häuser

Hauses

= 1 Lemma → Haus

... was wir auch zählen könnten:

- PoS-Tags
- N-Grams
- ...

Token:

= die konkrete Erscheinungsform eines Lexems

Type:

= das Muster/ die abstrakte Form


Type-Token-Ratio:

zur Einschätzung des Wortschatzreichtums eines Textes

Beim Zählen / Frequenzen auszählen des Lemmas werden alle drei Formen gezählt

→ $\text{count}(\text{Haus}) = 3$

Types, Tokens, ...



Frequenzen

Frequenz als Anzahl der Vorkommen eines *token* (oder *Lemma* oder *Pos-Tag* oder *N-Grams*) in einem Korpus.

Arten von Frequenzen:

- Absolute Häufigkeit
- Relative Häufigkeit
- Normierte Häufigkeit

Frequenzen

Absolute Frequenz	Relative Frequenz	Normalisierte / Normierte Frequenz
aF	rF	nF
Anzahl der Vorkommen eines Suchausdrucks im Korpus	Anzahl der Vorkommen eines Suchausdrucks im Korpus geteilt durch die Gesamtanzahl aller Token im Korpus	Anzahl der Vorkommen eines Suchausdrucks im Korpus geteilt durch die Gesamtanzahl aller Token im Korpus multipliziert mit 1'000'000
XY token	XY token / total token	XY token / total token * 1'000'000


Frequenzen vergleichen

Vergleichsgrundlage:

- Subkorpora
- Andere Korpora
- Synonyme
- ...

!Achtung, bei thematischen Korpora, die aufgrund von Vorkommnissen von bestimmten Wörtern zusammengestellt wurden.

Wortverteilungen | Zipfsches Gesetz



Daten statistisch auswerten: Kollokationen

Kollokationen

- Feste Wortverbindungen von einem Zielwort und seinen Kollokatoren
- Die Verbindung ist überzufällig häufig und wird daher als Kollokation gezählt
- Kollokationen können über unterschiedliche Masse berechnet werden und sagen dann je nachdem etwas anderes aus
- Um Kollokationen werden die Wörter rechts und links um das Wort (= *window*) betrachtet. Standardmässig beträgt das *window* oft 5, eine Anpassung ist aber meistens möglich

Kollokationen und Wortbedeutungen

„You shall know a word by the company it keeps.“ (John Rupert Firth 1957)

- Die ein Zielwort umgebenden Wörter beeinflussen und formen die Bedeutung des Zielwortes

Kollokationen sind Muster

... und wir kennen sie alle!

Ein paar Beispiele:

- Zähne putzen vs. Zähne waschen
- Hausaufgaben machen vs. Hausaufgaben erledigen
- Kaffee kochen vs. Kaffee zubereiten
- Hände waschen vs. Hände putzen

Kollokationen

Bundesrat will beim Frühfranzösisch durchgreifen: Alle Primarschülerinnen und Primarschüler in der Schweiz sollen eine zweite Landessprache lernen.

Der **Bundesrat** hat einen entsprechenden Gesetzesentwurf in die Vernehmlassung geschickt.

Die Landesregierung reagiert damit auf Bestrebungen verschiedener deutschsprachiger Kantone, Französisch aus dem Lehrplan zu streichen.

Nationaler Zusammenhalt gefährdet: Der **Bundesrat** zeigt sich über diese Entwicklung beunruhigt.

Dies widerspreche der Sprachenstrategie der Kantone. «Die sprachliche Vielfalt ist ein Grundpfeiler der Schweiz.

Sie ermöglicht es uns, einander zu verstehen», sagte Bundesrätin Elisabeth Baume-Schneider vor den Medien.

Das Abweichen einiger Kantone gefährde die «Harmonisierung des Unterrichts und den nationalen Zusammenhalt».

Bei der Diskussion gehe es nicht nur um eine pädagogische Frage. «Sie stellt die Mehrsprachigkeit unseres Landes infrage», so Baume-Schneider weiter. «Nur weil Mathematik schwierig ist, gibt man sie nicht auf.»

Quelle Ausschnitt aus: <https://www.srf.ch/news/schweiz/streit-um-fruehfranzoesisch-bundesrat-will-zweite-landessprache-an-primarschulen-durchsetzen> (16.06.2026)

Das richtige Mass verwenden




Figure 3.1 *Frequency and exclusivity scale*

Brezina, Vaclav (2018): Statistics in Corpus Linguistics. A Practical Guide. Cambridge: University Press, 75.

Exkurs: Stoppwörter

Stoppwörter / Stopwords

Stoppwörter sind Wörter oder Zeichen (Satzzeichen, Anführungszeichen, ...) oder *noise* (OCR-Fehler, ...) im Korpus, die häufig auftreten, wir aber teilweise in den Ergebnissen nicht sehen möchten, weil sie je nach Fragestellung/Erkenntnisinteresse nicht hilfreich scheinen.

! Oft lohnt sich ein erster Blick in die Daten ohne Stoppwortliste, die dann iterativ aufgebaut und verfeinert werden kann.

Daten vektorisieren: Word Embeddings


Die Idee von Word Embeddings

- Wie kann semantische Ähnlichkeit modelliert werden?
 - Wie kann semantische Ähnlichkeit „erlernt“ werden?
-
- Welche Wörter kommen im gleichen oder in ähnlichen Kontexten vor?
 - Wie können Wörter vektorisiert und dann in einen Raum projiziert werden?
 - Wie kann die Ähnlichkeit in einem hochdimensionalen Vektorraum veranschaulicht werden?

💡 Wörter mit ähnlicher Bedeutung erscheinen in ähnlichen Kontexten → *Distributional Hypothesis*

! Traditionelle Word Embeddings (wie wir sie auch heute rechnen) sind kontextunabhängig, d.h. die Bank (zum Sitzen) und die Bank (zum Geld anlegen) haben den gleichen Vektor.


Wieso Vektoren?



300 dieser Achsen

300-dimensionale Vektoren

Das sprachliche Paradigma & Syntagma




Linguistischer Hintergrund | Semantische Räume

	der die das	mystische_Kreatur	Mittagessen	Pferd	essen	...
magisch	12	19	6	31	6	
essen	42	8	60	10	15	
lecker	17	6	41	9	60	
Ritter	36	22	11	40	14	
...						


Linguistischer Hintergrund | Semantische Räume

	der die das	mystische_Kreatur	Mittagessen	Pferd	essen	...
magisch	12	19	6	31	6	
essen	42	8	60	10	15	
lecker	17	6	41	9	43	
Ritter	36	22	11	40	14	
...						

Linguistischer Hintergrund | Semantische Räume



Semantische Räume & Rechnen mit Word Embeddings



Mikolov, Tomas et al. (2013): Distributed representations of words an phrases and their compositionality. In: Advances in neural information processing systems. S. 3111-3119.

Nearest Neighbours

- Diejenigen Wörter, die am nächsten an einem Zielwort liegen werden *nearest neighbours* genannt.
- Diese Wörter können beispielsweise mithilfe der Kosinusähnlichkeit berechnet werden.

Mehr linguistische Hintergründe



<https://intro-korpusling-74864a.pages.uzh.ch>