

```
bins = list(range(start, stop, n_years))
labels = [f"{y}-{y + n_years - 1}" for y in bins[:-1]]

# Assign each document to a year bucket
# With n_years = 25:
# 1833 -> 1825 -> "1825-1849"
# 1900 -> 1900 -> "1900-1924"
# 1898 -> 1875 -> "1875-1899"
self.df["year_interval"] = pd.cut(self.df["year"], bins=bins, labels=labels, right=False)

# Calculate counts for each interval
interval_counters = {}
for interval in tqdm(labels, desc="Iterating intervals"):
    group_df = self.df[self.df["year_interval"] == interval]
```

Summer School 2026

Longue Durée digital – Kulturelle Phänomene und Ungleichheiten mit Machine Learning erforschen

Zürich, 17.-18.06.2026

EVALUATION

SARAH KIENER

EVALUATION

- Wichtiger Bestandteil jedes Machine-Learning-Projekts
- Gibt Überblick über Stärken und Schwächen des Modells:
 - Wie gut ist das Modell? Wie gut sind die Resultate?
 - Womit hat das Modell Schwierigkeiten? Gibt es systematische Fehler?
 - Was können wir tun, um systematische Fehler zu korrigieren?
 - Bei LLMs: Wie sehr schwanken die Ergebnisse von Durchgang zu Durchgang?


EVALUATIONSMETRIK

- Misst die Qualität der Ergebnisse
- Unterschiedliche Metriken für verschiedene Aufgaben
- Ist der Aufgabenstellung angepasst
 - Was wollen wir messen?
 - Was ist die zentrale Kennzahl?
- Kombination von verschiedenen Metriken / Tests für umfassendere Evaluation

GOLD-STANDARD / GROUND-TRUTH

- Manuell erstelltes Sample mit korrekten Antworten
- Modell-Output wird mit Gold-Standard verglichen
- Gold-Standard ist task-spezifisch
- Erstellung ist aufwändig und kostenintensiv
- Zuverlässige Evaluationsresultate

TRAIN – DEV – TEST SET



EVALUATION VON KLASSIFIKATIONSMODELLEN

RECALL, PRECISION, F1-SCORE, ACCURACY

EVALUATION VON KLASSIFIKATIONSMODELLEN

- **Precision:** Wie viele der als positiv klassifizierten Datenpunkt sind tatsächlich positiv?
- **Recall:** Wie viele positive Datenpunkte wurden korrekt erkannt?
- **F1-Score:** Harmonisches Mittel von Precision und Recall
 - Eignet sich gut für unausgeglichene Klassenverteilungen
- **Accuracy:** Anteil korrekt klassifizierter Datenpunkte
 - Nicht-geeignet für unausgeglichene Klassenverteilungen

KONFUSIONSMATRIX

Model \ GS	Malediven	ZRH
Malediven		
ZRH		



KONFUSIONSMATRIX

Model \ GS	Malediven	ZRH
Malediven	True Positive 	
ZRH		



KONFUSIONSMATRIX

Model \ GS	Malediven	ZRH
Malediven	True Positive 	
ZRH		True Negative 



KONFUSIONSMATRIX

Model \ GS	Malediven	ZRH
Malediven	True Positive 	False Negative 
ZRH		True Negative 



KONFUSIONSMATRIX

Model \ GS	Malediven	ZRH
Malediven	True Positive 	False Negative 
ZRH	False Positive 	True Negative 



ACCURACY

- Anteil korrekt klassifizierter Datenpunkte
- **Accuracy:** $\frac{TP+TN}{TP+TN+FP+FN} = \frac{\text{correct}}{\text{total}}$
- Fokussiert auf globale Korrektheit
- + Intuitiv und leicht verständlich
- Irreführend bei ungleich verteilten Klassen (class imbalance)

Beispiel:

- 2 von 50 Menschen leiden an einer Krankheit
- Modell klassifiziert alle als gesund
- Accuracy: $\frac{48}{50} = 96\%$
- Hohe Accuracy bei totalem Versagen des Modells

Model \ GS	Malediven	ZRH
Malediven	True Positive 	False Negative 
ZRH	False Positive 	True Negative 



PRECISION

		Model	
		GS	
GS	Malediven	True Positive 	False Negative 
	ZRH	False Positive 	True Negative 


- Wie viele der als **positiv klassifizierten** Datenpunkt sind tatsächlich positiv?
- **Precision:** $\frac{TP}{TP+FP}$
- Misst die Zuverlässigkeit eines Modells bei seinen positiven Vorhersagen
- Fokussiert auf die Qualität der Modell-Treffer
- Vermeidung von **False Positives**
- Precision ist besonders wichtig, wenn die Kosten eines «Fehlalarms» hoch und die Folgen gravierend sind
 - **Überwachung von Windkraftanlagen:** Bei einem Fehlalarm rückt ein Experten-Team umsonst aus, schaltet die Anlage tagelang ab und ersetzt teure Bauteile
 - **Unterstützung der Justiz:** Ein Angeklagter darf nur verurteilt werden, wenn er auch tatsächlich schuldig ist

RECALL

Model \ GS	Malediven	ZRH
Malediven	True Positive 	False Negative 
ZRH	False Positive 	True Negative 

- Wie viele der **tatsächlich positiven** Datenpunkte wurden korrekt als solche erkannt?
- **Recall:** $\frac{TP}{TP+FN}$
- Misst die Sensitivität / Trefferquote
- Von allen Fällen, die wir hätten finden müssen, wie viele haben wir tatsächlich erwischt?
- Vermeidung von **False Negatives**
- Recall ist besonders wichtig, wenn die Sicherheit und Erkennung von Gefahr Priorität hat und der Mehraufwand zu Überprüfung eines Fehlalarms in Kauf genommen wird
 - **Erkennung von Krankheiten:** Unnötige zusätzliche Abklärungen sind zwar belastend, aber weniger schlimm als das Übersehen einer Krankheit
 - **Flughafensicherheit:** Besser der Scanner piepst gelegentlich wegen eines Schlüssels, als dass eine gefährliche Waffe übersehen wird
 - **Autonomes Fahren:** Lieber einmal zu viel unnötig bremsen als einen Fussgänger zu überfahren

RECALL & PRECISION



High Precision 5/5

High Recall 5/5

High Precision 1/1

Low Recall 1/5

Low Precision 5/9

High Recall 5/5

Low Precision 0/4

Low Recall 0/5

RECALL & PRECISION

- Spannungsverhältnis zwischen Recall und Precision
- Trade-off, welches höher gewichtet werden soll



Spam-Filter
Wichtige Mails im Spam-Ordner
vs.
Spam-Mails im Posteingang



Corona-Pandemie
Gesunde in Quarantäne schicken
vs.
Kranke frei herumlaufen lassen




Betrugserkennung bei Kreditkarten
Sperrung harmloser Transaktionen
vs.
Nicht-Erkennen von Betrug

F1-SCORE

Model \ GS	Malediven	ZRH
Malediven	True Positive 	False Negative 
ZRH	False Positive 	True Negative 

- **Harmonisches Mittel** von Precision und Recall
- **F1-Score:** $\frac{2TP}{2TP+FP+FN} = 2 * \frac{precision * recall}{precision+recall}$
- Balance zwischen Precision und Recall
- Berücksichtigt gleichzeitig falsch Positive und falsch Negative
- Eignet sich bei unausgeglichener Klassenverteilung



AVERAGING



AVERAGING

Model \ GS	Malediven	ZRH
Malediven	240 	60 
ZRH	40 	660 

- Precision, Recall und F1-Score werden pro Klasse berechnet
- Mehrere Scores -> Wie erhalten wir einen aussagekräftigen Durchschnitt über alle Klassen hinweg?
- Wie berücksichtigen wir die unausgeglichene Klassenverteilung?
- Wie viel Gewicht erhält jede Klasse?

Klasse	Precision	Recall	F1-Score	Support
 Malediven	85.7 %	80.0 %	82.8 %	300
 ZRH	91.7 %	94.3 %	93.0 %	700
 Average	?	?	?	1000

MICRO-AVERAGE

- Gibt jeder **Instanz** das gleiche Gewicht
- True Positives, False Positives und False Negatives werden gepoolt
- Metriken werden über alle Klassen hinweg berechnet
- **Grosse Klassen** erhalten ein starkes Gewicht
- **Geeignet bei ausgewogener Klassenverteilung**
- Nicht geeignet bei unausgewogener Klassenverteilung
- Eng mit **Accuracy** verwandt
 - Entspricht der Accuracy bei **single-label** Klassifikation
 - Verschieden von Accuracy bei:
 - Multi-label Klassifikation
 - Subset von Klassen, die evaluiert werden

Model \ GS	Malediven	ZRH
Malediven	240 	60 
ZRH	40 	660 

MICRO-AVERAGE

Model \ GS	Malediven	ZRH
Malediven	240 	60 
ZRH	40 	660 

- Globale Summen bilden

- $\sum TP = TP_{\text{Mal}} + TP_{\text{ZRH}} = 240 + 660 = 900$
- $\sum FP = FP_{\text{Mal}} + FP_{\text{ZRH}} = 40 + 60 = 100$
- $\sum FN = FN_{\text{Mal}} + FN_{\text{ZRH}} = 60 + 40 = 100$

Klasse	Precision	Recall	F1-Score	Support
 Malediven	85.7 %	80.0 %	82.8 %	300
 ZRH	91.7 %	94.3 %	93.0 %	700
 Micro-Average	90.0 %	90.0 %	90.0 %	1000

MACRO-AVERAGE

Model \ GS	Malediven	ZRH
Malediven	240 	60 
ZRH	40 	660 

- Berechnet die Metriken für jede Klasse separat und nimmt den ungewichteten Mittelwert
- **Jede Klasse** hat das gleiche Gewicht
- Fokus auf **kleine Klassen**
- **Geeignet bei unausgewogener Klassenverteilung**, wenn kleine Klassen genauso wichtig sind wie grosse
 - z.B. medizinische Diagnostik von seltenen Krankheiten
- Verhindert, dass kleine Klassen vernachlässigt werden

Klasse	Precision	Recall	F1-Score	Support
 Malediven	85.7 %	80.0 %	82.8 %	300
 ZRH	91.7 %	94.3 %	93.0 %	700
 Macro-Average	88.7 %	87.2 %	87.9 %	1000

WEIGHTED AVERAGE

Model \ GS	Malediven	ZRH
Malediven	240  MLE	60 
ZRH	40  MLE	660 

- Berechnet die Metriken für jede Klasse separat und nimmt den **gewichteten** Mittelwert
- Der Score für jede Klasse wird mit ihrem Support (Anzahl Instanzen pro Klasse) multipliziert
- Dann wird durch die totale Anzahl Samples geteilt
- Fokus auf **grossen Klassen**
- Vernachlässigt kleine Klassen
- Widerspiegelt die **tatsächliche Klassen-Verteilung**
- Gut geeignet, wenn kleine Klassen nur einen kleinen Effekt haben
 - z.B. ein Koffer, der nicht ankommt, hat immer gleichen negativen Effekt unabhängig von der Destination
-> kleine Klassen müssen nicht speziell berücksichtigt werden

WEIGHTED AVERAGE

Model \ GS	Malediven	ZRH
Malediven	240 	60 
ZRH	40 	660 

- $P_{weighted} = \frac{85.7 \times 300 + 91.7 \times 700}{1000}$
- $R_{weighted} = \frac{80.0 \times 300 + 94.3 \times 700}{1000}$
- $F1_{weighted} = \frac{82.8 \times 300 + 93.0 \times 700}{1000}$

Klasse	Precision	Recall	F1-Score	Support
 Malediven	85.7 %	80.0 %	82.8 %	300
 ZRH	91.7 %	94.3 %	93.0 %	700
 Weighted Average	89.9 %	90.0 %	89.9 %	1000

AVERAGING

Model \ GS	Malediven	ZRH
Malediven	240 	60 
ZRH	40 	660 

Klasse	Precision	Recall	F1-Score	Support
 Malediven	85.7 %	80.0 %	82.8 %	300
 ZRH	91.7 %	94.3 %	93.0 %	700
 Micro-Average	90.0 %	90.0 %	90.0 %	1000
 Macro-Average	88.7 %	87.2 %	87.9 %	1000
 Weighted Average	89.9 %	90.0 %	89.9 %	1000

INTER ANNOTATOR AGREEMENT



INTER ANNOTATOR AGREEMENT

- Misst die **Übereinstimmung** zwischen mehreren Annotatoren (Personen oder Modell)
- Misst die **Objektivität und Qualität von Datenbeschriftungen / Labels**
 - Annotieren die Annotatoren mehrheitlich die gleichen Labels?
 - Wie objektiv ist die Labelvergabe?
 - Sind die **Richtlinien klar** und die **Daten verlässlich**?
 - Wird subjektiv nach Bauchgefühl und mit unklaren Richtlinien annotiert?
 - Widerspiegelt die Komplexität der Fragestellung und Labelvergabe
- Kann zwischen menschlichen Annotatoren oder Mensch und Maschine berechnet werden

COHEN'S KAPPA (κ)

- Misst die Übereinstimmung zwischen **zwei** Annotatoren
- Rechnet Zufallsübereinstimmungen mathematisch heraus

$$\kappa = \frac{p_0 - p_e}{1 - p_e}$$

- p_0 : Beobachtete Übereinstimmung

- $\frac{15 + 70}{100} = 0.85$

- p_e : Zufallsübereinstimmung

- $p_{\text{Malediven}} = \frac{15 + 5}{100} \times \frac{15 + 10}{100} = 0.05$

- $p_{\text{ZRH}} = \frac{10 + 70}{100} \times \frac{5 + 70}{100} = 0.60$

- $p_e = p_{\text{Malediven}} + p_{\text{ZRH}} = 0.05 + 0.60 = 0.65$

- $\kappa = \frac{0.85 - 0.65}{1 - 0.65} = 0.571$

A \ B	B	Malediven	ZRH
Malediven		15	5
ZRH		10	70

Cohen's κ	Interpretation
< 0.00	Keine Übereinstimmung
0.00	Zufallsübereinstimmung
0.01 – 0.20	Geringe Übereinstimmung
0.21 – 0.40	Mässige Übereinstimmung
0.41 – 0.60	Deutliche Übereinstimmung
0.61 – 0.80	Beachtliche Übereinstimmung
0.81 – 1.00	(Fast) perfekte Übereinstimmung

verlässliche Daten

EVALUATION VON LLMS



EVALUATION VON LLMS

- **Problem:** LLM-Outputs sind nicht deterministisch
- Konsistenz / Stabilität der LLM-Antworten sollte gemessen werden
- Mögliche Ansätze zur Messung der Label-Konsistenz bei LLMs:
 - **Cohen's Kappa** zwischen LLM und Mensch berechnen
 - **Durchschnittliche Scores und Standardabweichungen**
 - 10-mal dieselben Daten annotieren lassen
 - Durchschnitt und Standardabweichung von Precision, Recall und F1-Score berechnen
 - **Fleiss' Kappa**
 - 10-mal dieselben Daten annotieren lassen
 - Fleiss' Kappa zwischen den 10 Durchgängen berechnen, um Konsistenz zu messen
 - Fleiss' Kappa ist eine Erweiterung von Cohen's Kappa, um die Übereinstimmung zwischen mehr als zwei Annotatoren zu berechnen